

Niveau	Nb	Description
■ Critique	5	Impact direct sur les analyses et recommandations
■ Significatif	4	Qualité analytique et crédibilité du livrable
■ À préciser	3	Points à documenter ou à mentionner pour le pitch

Incohérences critiques

1	480 boutiques sans coordonnées GPS — non traitées dans le livrable	■ CRITIQUE
Notebooks concernés	Étape 3 (cellule 12) → Étape 8 (section cartographie)	
Output révélateur	Boutiques SANS coordonnées (non cartographiables) : 480	

Sur 1 068 boutiques uniques du dataset SUD-EST, seulement 588 disposent de coordonnées GPS. Les 480 restantes (45 % du réseau) sont non cartographiables. Le contrôle qualité post-jointure détecte bien 108 549 nulls sur latitude/longitude et lève une alerte "ALERTE", mais aucune décision corrective n'est prise ni documentée. Le livrable final présente la carte et les analyses spatiales comme si elles couvraient l'ensemble du réseau, ce qui est inexact.

De plus, la fonction grille_decision() impute dist = 10 par défaut quand la distance est NaN, ce qui affecte silencieusement les recommandations FERMER/MAINTENIR/DÉVELOPPER pour ces boutiques sans position connue.

2	Perte de 30,57 % des données lors du nettoyage — non discutée	■ CRITIQUE
Notebook concerné	Étape 2 (cellule 26) — Bilan nettoyage	
Output révélateur	Lignes après filtre SUD-EST : 326 478 → après nettoyage : 226 677 (perte : 99 801 lignes, 30,57 %)	

La suppression de 81 107 doublons représente 24,8 % du dataset SUD-EST — un taux anormalement élevé. Ces lignes pourraient être des acquisitions légitimes identiques (même produit, même boutique, même profil client le même mois). Aucune vérification n'est faite pour distinguer les vrais doublons des acquisitions multiples réelles.

Le guide précise explicitement qu'une perte > 5 % doit déclencher une alerte. Ici, le livrable final mentionne "Doublons supprimés" sans quantifier ni justifier cette perte massive, ce qui fragilise la crédibilité de l'ensemble de l'analyse.

3

La variable trimestre est fausse — 100 % des lignes en Q4

■ CRITIQUE

Notebook concerné	Étape 5 (cellule 3) — Variables temporelles
Output révélateur	trimestre / Q4 : 226 677 (toutes les lignes)

La variable trimestre est calculée depuis PERIOD_MM, mais les données ne couvrent que les mois 10, 11 et 12 (octobre à décembre 2021 et 2022). Tous les mois tombent donc en Q4. La variable est ensuite utilisée dans l'analyse saisonnière (Étape 6) qui produit un graphique "Volume par trimestre" ne montrant qu'une seule barre.

L'analyse saisonnière est vide de sens et ne devrait pas figurer dans le livrable sous cette forme. Il faudrait soit supprimer ce graphique, soit le remplacer par une analyse par mois (Oct/Nov/Déc) en commentant l'absence de données pour les autres trimestres.

4

La catégorie OUVRIR est absente de la grille de décision

■ CRITIQUE

Notebook concerné	Étape 7 (cellule 10) — Grille de décision
Output révélateur	FERMER : 965 / MAINTENIR : 60 / DÉVELOPPER : 43 / OUVRIR : 0

La fonction grille_decision() ne contient aucune branche pour le cas OUVRIR. Le résultat est zéro boutique recommandée à l'ouverture, alors que le guide identifie les zones sans boutique (population INSEE élevée, NRO imminent, distance clients > 30 km) comme un cas d'usage central de l'analyse.

L'Étape 8 reprend ce tableau dans le livrable final sans signaler l'absence de la catégorie. Le graphique de synthèse des recommandations comporte une barre OUVRIR à 0 sans aucun commentaire. C'est l'une des failles les plus susceptibles d'être relevées lors du pitch.

5

Distance client/boutique calculée pour seulement 11,8 % des lignes

■ CRITIQUE

Notebook concerné	Étape 5 (cellules 7-8) — Haversine
Taux de couverture	26 835 distances calculées / 226 677 lignes → 11,8 % des acquisitions
Cause	Table manuelle VILLES_FR : 60 villes référencées pour 1 779 villes uniques dans les données (couverture 1,4 %)

La variable distance_km est la variable jugée "la plus importante à créer" par le guide. Elle est utilisée comme critère de décision (profil local vs régional) et comme base du rayon de chalandise. Avec 88 % de valeurs manquantes, les conclusions tirées de cette variable sont statistiquement non représentatives.

Le fallback silencieux dist = 10 km dans grille_decision() pour les valeurs NaN constitue une hypothèse implicite non documentée qui affecte les recommandations de 480 boutiques sans distance connue.

Incohérences significatives

6

Les LINE_TYPE réels (T, I, M) ne correspondent pas au guide (T, B, F)

■ SIGNIFICATIF

Notebook concerné	Étape 5 (cellule 14) — part_mobile / part_fixe
Output révélateur	LINE_TYPE uniques dans les données : ['T', 'I', 'M']
Dictionnaire ARPU utilisé	ARPU = {'T': 200, 'B': 350, 'F': 350} — I et M tombent dans ARPU_DEFAULT = 200 EUR

Le guide indique T = mobile, B = box, F = fixe. Or les données contiennent T, I et M — sans qu'aucun notebook ne documente la correspondance réelle. M représente 35 % des acquisitions et I représente 29,3 %. Ces deux types sont traités comme du "mobile à 200 EUR" faute de mapping explicite, ce qui biaise l'estimation du CA pour plus de 64 % des acquisitions.

7

La période annoncée dans le livrable est fausse (2020-2024 vs 2021-2022)

■ SIGNIFICATIF

Notebook concerné	Étape 8 (cellule 3) — Introduction livrable
Déclaré dans le livrable	"Acquisitions clients 2020-2024"
Réalité des données	Début : 2021-10-01 / Fin : 2022-12-01 (15 mois, oct. 2021 à déc. 2022)

L'introduction du livrable final mentionne une période 2020-2024 qui ne correspond pas aux données réelles. C'est une erreur factuelle directement visible dans les outputs de l'Étape 2 (cellule 13). Un jury qui consulte les données ou pose la question pendant le pitch identifiera immédiatement cette incohérence.

8

Les 4 boutiques en tête de classement ont un emplacement NaN

■ SIGNIFICATIF

Notebook concerné	Étape 6 (cellule 9) — Top 15 boutiques
Boutiques concernées	SOSHOES (19 778 acq.), PDV-MYSHOP (15 335), ONEESHOP (12 752), VADPCM (8 741)
Impact	Ces 4 boutiques représentent ~43 % du CA total estimé régional (emplacement = NaN → coût imputé CV 65 000 €)

Les boutiques dominantes du classement ont toutes emplacement = NaN. Leur coût de fonctionnement est imputé par défaut à 65 000 € (CV) sans justification. Comme elles concentrent un volume disproportionné, elles faussent tous les benchmarks régionaux (CA médian, marge médiane, % boutiques rentables). Ce biais structurel n'est mentionné nulle part dans le livrable.

9

Suppression des doublons sans vérification métier préalable

■ SIGNIFICATIF

Notebook concerné	Étape 2 (cellule 9) — Suppression doublons
Quantité supprimée	81 107 lignes 100% identiques — soit 24,8 % du dataset SUD-EST

Le nettoyage supprime toutes les lignes 100 % identiques sans vérifier si elles correspondent à de vraies erreurs de saisie ou à des acquisitions multiples légitimes (même client, même boutique, même produit le même mois). Dans un contexte de vente télécom, deux acquisitions identiques pourraient représenter deux clients différents avec le même profil. Cette décision aurait dû être documentée et justifiée dans le journal de nettoyage et dans le livrable.

Points à corriger ou préciser pour le pitch1
0**Score de rentabilité médian = 0,0x — non commenté**

■ À PRÉCISER

Notebook concerné	Étape 6 (cellule 7) — Benchmark CC vs CV
Output révélateur	score_median = 0.0 pour CC et CV / Volume médian par boutique : 8 acquisitions / Marge médiane : -64 400 EUR

Le résultat est analytiquement cohérent — 8 acquisitions × 200 EUR ARPU = 1 600 EUR de CA pour 65 000 € de coût fixe — mais il n'est interprété nulle part. C'est pourtant le chiffre clé du projet : 90,4 % des boutiques ne couvrent pas leurs coûts fixes. Ce constat devrait être mis en avant comme conclusion centrale de l'analyse, pas laissé dans un output silencieux.

1
1**Corrélation surface × volume = 0,038 — résultat non commenté**

■ À PRÉCISER

Notebook concerné	Étape 4 (cellule 21) — Analyse bivariée
Output révélateur	Corrélation Surface / Volume : 0.038 (quasi nulle)

La corrélation entre la surface d'une boutique et son volume de ventes est quasi nulle ($r = 0,038$). Ce résultat contre-intuitif — une grande boutique ne vend pas plus qu'une petite — est analytiquement très intéressant et exploitable dans le pitch. Il aurait dû être commenté et intégré dans les recommandations (surface ≠ levier de performance).

1
2**PERSON_BIRTH_DT_year à 5,43 % de nulls — seuil dépassé, non signalé**

■ À PRÉCISER

Notebook concerné	Étape 2 (cellule 5) — Valeurs manquantes
Output révélateur	PERSON_BIRTH_DT_year : 176 805 nulls (5,43 %) — seuil guide : < 5 %

Le guide fixe un seuil d'acceptabilité à < 5 % de nulls. PERSON_BIRTH_DT_year est à 5,43 %, au-dessus de ce seuil. La colonne est utilisée pour calculer age_client — les lignes avec NaN produisent un âge NaN, non imputé, exclu silencieusement des analyses démographiques. Aucune décision documentée n'est prise à ce sujet, ce qui devrait au minimum figurer dans le journal de nettoyage.

Synthèse — Priorités avant le pitch

Priorité	Point	Action recommandée
1 — Critique	OUVRIR absent de la grille	Ajouter une branche OUVRIR basée sur zones INSEE / NRO / distance > 30 km
2 — Critique	Période fausse dans le livrable	Corriger "2020-2024" → "Oct. 2021 – Déc. 2022 (15 mois)"
3 — Critique	Analyse saisonnière vide	Supprimer le graphique trimestre ou le remplacer par une analyse mensuelle Oct/Nov/Déc
4 — Significatif	LINE_TYPE non documentés	Ajouter une slide ou note explicitant T=mobile, I=internet/box, M=? avec hypothèse choisie
5 — À anticiper	480 boutiques sans coords	Mentionner proactivement comme limite : "45 % du réseau non géolocalisable avec les données disponibles"

Les incohérences 2 (perte 30,57 %) et 8 (boutiques NaN en tête) sont mieux présentées comme des **limites assumées et documentées** plutôt que comme des erreurs — ce qui est plus crédible analytiquement qu'espérer qu'elles passent inaperçues.