

Optimisation du Reseau de Boutiques TELECOM

GROUPE 5			REGION SUD-EST			5_SUD_EST		
ETAPE 0	ETAPE 1	ETAPE 2	ETAPE 3	ETAPE 4	ETAPE 5	ETAPE 6	ETAPE 7	ETAPE 8
Preparation	Comprehension	Nettoyage	Jointure	Exploration	Nouvelles Var.	Analyse	Business	Livable
4 fichiers		1 ligne		3 tables		Groupe 5		
a exploiter		= 1 acquisition client		a joindre		SUD-EST uniquement		

0 PREPARATION — Telechargement & Organisation

Fichiers a telecharger depuis Google Drive

Fichier	Type	Contenu	Priorite
README.xlsx	Excel	Dictionnaire de toutes les variables	LIRE EN 1er
Fichier_principal.csv	CSV	Acquisitions clients — table principale	ESSENTIEL
COORD_BQT.csv	CSV	Coordonnees GPS, surface, emplacement boutiques	ESSENTIEL
LIB_BQT.csv	CSV	Canal marketing, type CC/CV	ESSENTIEL

CONSEIL Commence TOUJOURS par lire le README.xlsx en entier avant d'ouvrir les autres fichiers.

1 COMPRENDRE LES DONNEES — Cartographie des variables

Structure de la table principale (Fichier_principal.csv)

LINE_TYPE Type de produit vendu (mobile, box, fixe...) — variable cle pour segmenter Categ.	PERIOD Date de l'acquisition — permet l'analyse temporelle N vs N-1 Date
ORDER_SHOP_CD Code de la boutique — CLE DE JOINTURE avec les autres tables ID	PERSON_BIRTH_DT_year Annee de naissance → calculer l'age du client a l'achat Num.
CITY_LN Ville du client → calculer distance client/boutique Texte	ZONE Zone commerciale → FILTRER sur '5_SUD_EST' pour notre groupe Categ.
GeoLife Segment socio-demographique du client (profil de vie) Categ.	


Tables secondaires — Variables cles

Table	Variable	Type	Utilite
COORD_BQT	surface	Num.	Taille de la boutique en m2
COORD_BQT	emplacement	Categ.	CC (Centre-Commercial) ou CV (Centre-Ville)
COORD_BQT	latitude	Num.	Coordonnee GPS — calcul de distance

COORD_BQT	longitude	Num.	Coordonnee GPS — calcul de distance
LIB_BQT	canal	Categ.	Canal marketing de la boutique
LIB_BQT	ORDER_SHOP_CD	ID	Cle de jointure avec table principale

CONSEIL La variable ORDER_SHOP_CD est presente dans les 3 tables — c'est TA CLE DE JOINTURE. Verifie qu'elle est propre (pas d'espaces, meme format) avant toute jointure.

Schema relationnel — Vue d'ensemble



2 NETTOYAGE DES DONNEES — Etape la plus critique

ATTENTION — A faire avant TOUTE analyse

Des donnees sales = des analyses fausses = des recommandations erronees

Documente chaque decision de nettoyage (ex: 'supprime X lignes car valeurs nulles sur champ Y')

Conserve toujours une copie du fichier brut original

Plan de nettoyage — Fichier principal

Verification	Ce qu'il faut faire	Indicateur attendu
Valeurs manquantes	Compter les NaN par colonne. Decider : supprimer la ligne ou imputer ?	< 5% de nulls acceptable
Doublons	Verifier les lignes 100% identiques. Les supprimer.	0 doublon
ZONE = 5_SUD_EST	Filtrer UNIQUEMENT les lignes de notre groupe avant tout travail	Dataset reduit
ORDER_SHOP_CD	Verifier format uniforme (ex: pas d'espaces, meme casse)	Format coherent
PERIOD	Verifier le format de date. Convertir si necessaire (ex: YYYYMM -> date)	Type datetime
PERSON_BIRTH_DT_year	Verifier les valeurs aberrantes (ex: annee < 1920 ou > 2010)	Plage realiste
CITY_LN	Normaliser la casse (majuscules/minuscules). Verifier les villes connues SUD-EST	Villes coherentes
Geolife	Verifier les categories connues. Unifier les noms si variantes	Categories stables

Verification de la jointure (apres merge)

Verification post-jointure	Signe d'alerte
Nombre de lignes avant vs apres la jointure identique	Si perte > 5% -> probleme de cle
Aucune boutique du SUD-EST sans coordonnees GPS	Boutiques sans coords = non cartographiables
Aucune boutique sans libelle CC/CV	Type emplacement requis pour le modele de cout
Colonnes dupliquees absentes (ex: colonne_x, colonne_y)	Renommer ou supprimer les doublons

CONSEIL Garde un fichier 'journal_nettoyage.txt' ou tu notes chaque decision prise et son impact (ex: '47 lignes supprimees car CITY_LN vide'). C'est essentiel pour l'annexe du livrable.

3 JOINTURE DES TABLES — Construction de la base de travail

Ordre des operations

- **Etape 3.1** Filtrer Fichier_principal sur ZONE = '5_SUD_EST' -> table_sud_est
- **Etape 3.2** Joindre table_sud_est avec COORD_BQT sur ORDER_SHOP_CD -> table_geo
- **Etape 3.3** Joindre table_geo avec LIB_BQT sur ORDER_SHOP_CD -> table_finale
- **Etape 3.4** Verifier le resultat (lignes, colonnes, nulls residuels)
- **Etape 3.5** Sauvegarder en CSV -> 'base_travail_SUD_EST.csv'

Controles qualite post-jointure

Controle	Valeur avant	Valeur apres	Statut
Nb lignes totales	?	Doit etre = avant filtre SUD_EST	A verifier
Nb boutiques uniques	?	Doit matcher COORD_BQT filtre	A verifier
Nulls sur latitude/longitude	0	Doit etre 0 apres jointure	A verifier
Nulls sur emplacement CC/CV	0	Doit etre 0 apres jointure	A verifier
Nb colonnes	7	Environ 12-14 colonnes finales	A verifier

4 EXPLORATION DES DONNEES — Plan d'analyse detaille

4a Analyse univariee — Variable par variable

Variable	Ce que tu calcules	Visualisation ideale
LINE_TYPE	Comptage par categorie, % du total	Camembert ou barres

PERIOD	Nb acquisitions par mois/trimestre/an	Courbe temporelle
ORDER_SHOP_CD	Top / Flop boutiques par volume	Classement barre
PERSON_BIRTH_DT_year	Tranche d'age, age moyen, mediane	Histogramme
Geolife	Repartition des segments, % par boutique	Barres empilees
emplacement	Nb boutiques CC vs CV, % volume chacun	Donut ou barre
surface	Min, Max, Moyenne, distribution	Boxplot

4b Analyse bivariee — Croisements pertinents

Croisement	Question metier repondue	Visualisation
LINE_TYPE x PERIOD	Quels produits progressent dans le temps ?	Courbe par produit
LINE_TYPE x ORDER_SHOP_CD	Chaque boutique est-elle specialisee ?	Heatmap ou barre empilee
Geolife x LINE_TYPE	Quels profils clients achètent quoi ?	Barre groupée
Age x LINE_TYPE	Correlation age / type de produit ?	Boxplot par produit
surface x Volume ventes	Les grandes boutiques vendent-elles plus ?	Nuage de points
emplacement x Volume	CC ou CV plus performant en SUD-EST ?	Barres comparees

4c Analyse temporelle — Evolution N vs N-1

- Extraire l'annee depuis PERIOD -> comparer chaque boutique sur 2 annees consecutives
- Calculer le taux de croissance : $(\text{Volume}_N - \text{Volume}_{N-1}) / \text{Volume}_{N-1} * 100$
- Identifier les boutiques a forte croissance (+20%), stables, en declin (-20%)
- Analyser si le mix produit evolue (ex: montee de la fibre, baisse du mobile prepaye)
- Visualisation : tableau avec fleches vertes/rouges + taux de croissance par boutique

4d Analyse spatiale SUD-EST — Focus géographique

- Calculer la distance moyenne client/boutique par boutique (formule Haversine avec lat/lon)
- Identifier les boutiques a fort rayon (clients viennent de loin = besoin reel)
- Reperer les zones geographiques du SUD-EST non couvertes (villes importantes sans boutique proche)
- Zones cles a analyser : Marseille, Nice, Toulon, Avignon, Montpellier, Nimes, Aix-en-Provence
- Croiser avec les donnees INSEE de population par commune

CONSEIL Pour le SUD-EST : regarde specifiquement les zones littorales (tourisme saisonnier) et les zones montagne (faible couverture). Ce sont souvent les plus interessantes pour les recommandations.

5 CREATION DE NOUVELLES VARIABLES — Feature Engineering

Variables a creer absolument

Nouvelle variable	Comment la calculer	Utilite analytique
age_client	Annee_reference - PERSON_BIRTH_DT_year	Segmenter par tranche d'age
tranche_age	age_client -> '18-25', '26-40', '41-60', '60+'	Visualisations plus lisibles
annee	Extraire l'annee depuis PERIOD	Analyse temporelle N vs N-1
trimestre	Extraire le trimestre depuis PERIOD	Saisonnalite
distance_km	Haversine(lat_boutique, lon_boutique, lat_ville_client)	Rayon de chalandise
rayon_chalandise	Bucketiser distance_km : <5, 5-20, 20-50, >50 km	Segmentation spatiale
croissance_yoy	(Vol_N - Vol_N-1) / Vol_N-1 par boutique	Identifier tendances
part_mobile	Nb achats mobile / Total achats par boutique	Specialisation boutique
part_fixe	Nb achats fixe / Total achats par boutique	Specialisation boutique
score_rentabilite	CA_estime / Cout_fonctionnement par boutique	Modele business

CONSEIL La variable 'distance_km' est la plus importante a creer. Elle permet de savoir si une boutique sert une clientele locale ou regionale, ce qui est cle pour les recommandations d'ouverture.

Variables optionnelles (enrichissement open data)

- **population_commune** -> INSEE : potentiel de marche de la zone de chaque boutique
- **nro_a_moins_de_Xkm** -> ARCEP : nombre de NRO (fibres) a moins de 5km de la boutique
- **flux_pieton_zone** -> open data mobilite : attractivite de la zone (utile pour CC)
- **nb_boutiques_concurrentes** -> open data : intensite de la concurrence locale

6 ANALYSE METIER — Caracterisation des boutiques SUD-EST

Tableau de bord par boutique — Variables cles a produire

Metrique boutique	Calcul	Benchmark interne
Volume total acquisitions	COUNT(*) GROUP BY ORDER_SHOP_CD	Mediane des boutiques SUD-EST
Part mobile vs fixe vs box	COUNT par LINE_TYPE / Total	Mix regional moyen
Age moyen des clients	MEAN(age_client)	Comparer aux autres boutiques
Distance moyenne client	MEAN(distance_km)	< 10km = local, > 20km = regional
Segment Geolife majoritaire	MODE(Geolife)	Profil dominant
Taux de croissance annuel	croissance_yoy en %	> 0% = croissance
Emplacement	CC ou CV	Impact sur les couts
Surface boutique	surface en m2	Taille relative

Sources open data SUD-EST a integrer

Source	URL / Acces	Variable a extraire
INSEE Communes	insee.fr -> recensement	Population par commune SUD-EST
ARCEP NRO	arcep.fr -> observatoire	Localisation Noeuds Raccordement Optique
data.gouv.fr	data.gouv.fr -> mobilite	Flux de deplacement & transports
OpenStreetMap	overpass-api.de	Commerces & concurrents telecom

7 MODELE BUSINESS — Rentabilite & Recommandations

Structure de couts (donnees fournies)

CENTRE-COMMERCIAL	CENTRE-VILLE	OUVERTURE / RELOCALISATION
85 000 EUR / an	65 000 EUR / an	450 000 EUR
Cout annuel de fonctionnement	Cout annuel de fonctionnement	Cout unique (amortir sur N annees)

Modelisation du CA — Hypotheses a formuler

Element	Methode de calcul	Donnee source
Volume d'acquisitions par boutique/an	COUNT des lignes filtrees	Fichier_principal
Panier moyen mobile	Hypothese ARPU: ~200 EUR/an/client	Rapport ARCEP public
Panier moyen box/fixe	Hypothese ARPU: ~350 EUR/an/client	Rapport ARCEP public
CA estime	SUM(volume_type x ARPU_type) par boutique	Calcul
Marge estimee	CA estime - Cout fonctionnement (CC/CV)	Calcul
Retour sur invest.	450 000 / Marge_annuelle = N annees	Calcul

Grille de decision finale — Par boutique

FERMER	MAINTENIR	DEVELOPPER	OUVRIR
Non rentable Tendance < -20% Boutique proche existante	Rentable Stable Zone couverte Clientele fidelisee	Rentable Croissance > +15% Fibre NRO a venir Zone sous-equipee	Zone sans boutique Pop. elevee INSEE NRO imminent Distance clients > 30km

Plan du rapport

#	Section	Contenu attendu	Volume
1	Introduction	Perimetre SUD-EST, contexte marche telecom, objectifs	1 p.
2	Donnees & Methode	Description des fichiers, plan de nettoyage, jointures	2 p.
3	Analyse descriptive	Stats univariees, bivariees, temporelles + cartes geo	3-4 p.
4	Nouvelles variables	Justification des variables creees, statistiques	1 p.
5	Modele business	Hypotheses ARPU, calcul CA, rentabilite par boutique	2 p.
6	Recommandations	Tableau FERMER/MAINTENIR/DEVELOPPER/OUVRIR + justifs	2 p.
7	Annexes	Sources open data, journal de nettoyage, limites	1 p.

POINTS DE VIGILANCE CRITIQUES

1. Pas de CA dans les donnees -> toutes les hypotheses de revenus doivent etre explicitement formulees et justifiees (sinon 0 credibilite)
2. Pas de cle client -> impossible de suivre un client dans le temps, seulement les acquisitions (pas de churn, pas de LTV)
3. La colonne PERIOD est centrale -> verifier son format avant toute analyse temporelle
4. NRO (ARCEP) -> vrai avantage concurrentiel dans votre analyse strategique SUD-EST, zone a fort deploiement fibre
5. Documenter TOUTES les decisions de nettoyage et les hypotheses -> c'est ce qui est evalue